

期末复习

主成分分析

PCA 算法: 是一种常用的数据降维技术、属于无监督学习, 通过线性变换将高维数据映射到低维空间。
→ 将高维数据转换为低维数据, 同时尽可能保留原始数据信息
↓ 目的: 减少数据维度, 降低计算成本, 提高模型效率与准确性, 同时减少数据冗余和噪声

① 对样本矩阵去中心化, 得到新的矩阵X

特征1 特征2 特征n
样本1 $\begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \end{bmatrix}$
样本2 $\begin{bmatrix} x_{21} & x_{22} & \dots & x_{2n} \end{bmatrix}$
...
样本m $\begin{bmatrix} x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix}$

$$\Rightarrow X = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \dots & x_{1n} - \bar{x}_n \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \dots & x_{2n} - \bar{x}_n \\ \dots & \dots & \dots & \dots \\ x_{m1} - \bar{x}_1 & x_{m2} - \bar{x}_2 & \dots & x_{mn} - \bar{x}_n \end{bmatrix}$$

② 求去中心化矩阵X的协方差矩阵C → 衡量两个特征之间的相关性, 值越大, 相关性越强

$$C = \begin{bmatrix} \text{COV}(x_1, x_1) & \text{COV}(x_1, x_2) & \dots & \text{COV}(x_1, x_n) \\ \text{COV}(x_2, x_1) & \text{COV}(x_2, x_2) & \dots & \text{COV}(x_2, x_n) \\ \dots & \dots & \dots & \dots \\ \text{COV}(x_n, x_1) & \text{COV}(x_n, x_2) & \dots & \text{COV}(x_n, x_n) \end{bmatrix}$$

$$\text{COV}(x_1, x_2) = \frac{1}{m-1} \sum_{i=1}^m (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2)$$

③ 求协方差矩阵C的特征值和特征向量

$$(C - \lambda I)V = 0$$

④ 对特征进行筛选, 保留最大的K个特征, 将K个特征向量组成降维矩阵W
(特征值从大到小排序, 取出前K个特征值及其特征向量V, 用K个特征向量组成n行K列降维矩阵W)

$$W = [v_1', v_2', \dots, v_K']_{n \times k}$$

⑤ 对去中心化矩阵X进行矩阵变换, 得到映射后的K维矩阵Y, $Y_{m \times k} = X_{m \times n} \times W_{n \times k}$

代码:

```
from sklearn.decomposition import PCA
pca = PCA(n_components=2)
data_pca = pca.fit_transform(data)
```

线性判别分析法(LDA): 将数据投影到一维, 使得每一类相近数据投影点尽可能近, 不同类别数据尽可能远离。

↓
类内离散度尽可能小(紧凑) $\Rightarrow \max \|W^T u_0 - W^T u_1\|_2^2 \rightarrow$ 两个类别的数据中心距离
类间离散度尽可能大(分离) $\Rightarrow \min W^T \Sigma_0 W + W^T \Sigma_1 W \rightarrow$ 同类样本投影点的协方差。

① 计算类内离散度矩阵 S_w

$$S_w = \sum_{i=1}^C \sum_{j=1}^{N_i} (x_j^{(i)} - u_i)(x_j^{(i)} - u_i)^T \Rightarrow \text{两类: } S_w = \sum_{x \in x_0} (x - u_0)(x - u_0)^T + \sum_{x \in x_1} (x - u_1)(x - u_1)^T$$

② 计算类间离散度矩阵 S_b

$$S_b = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T \Rightarrow \text{两类: } S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

③ 计算相关矩阵

求 $S_w^{-1} S_b$ 特征值、特征向量

④ 计算相关矩阵的最大的d个特征值和特征向量, 组成投影矩阵W

$$S_b W = \lambda S_w W$$

⑤ 转化样本集中每个样本, 得到新样本集 $X_{\text{new}} = X \times W$

$$W = S_w^{-1} (\mu_1 - \mu_2) \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

```
from sklearn.discriminant_analysis import
LinearDiscriminantAnalysis
import numpy as np
```

```
# 示例数据
X = np.array([[ -1, -1], [-2, -1], [-3, -2], [1, 1], [2, 1], [3, 2]])
y = np.array([0, 0, 0, 1, 1, 1])
```

```
# LDA模型训练
lda = LinearDiscriminantAnalysis(n_components=1)
X_lda = lda.fit_transform(X, y)
```

```
# 查看投影向量
print("投影方向:", lda.coef_)
print("截距:", lda.intercept_)
```

PCA 与 LDA 比较

特性	LDA	PCA
监督性	需要类别标签 (监督学习)	无监督学习
优化目标	最大化类别可分性	最大化方差
投影方向数	最多 C - 1 维 (C 为类别数)	无限制
适用场景	分类问题	通用降维
对旋转的敏感性	敏感	不变

数据集详情

- 类别 C_0 (标签0) : (1, 2), (2, 3), (3, 4) (3个样本) ;
- 类别 C_1 (标签1) : (2, 1), (3, 2), (4, 3) (3个样本) ;
- 特征矩阵 X (6×2) :

$$X = \begin{pmatrix} 1 & 2 \\ 2 & 3 \\ 3 & 4 \\ 2 & 1 \\ 3 & 2 \\ 4 & 3 \end{pmatrix}$$
- 类别标签 $y = [0, 0, 0, 1, 1, 1]$ 。

PCA 计算:

① $\bar{x}_1 = 2.5$
 $\bar{x}_2 = 2.5$ 去中心化 $X = \begin{bmatrix} -1.5 & -0.5 \\ -0.5 & 0.5 \\ 0.5 & 1.5 \\ -0.5 & -1.5 \\ 0.5 & -0.5 \\ 1.5 & 0.5 \end{bmatrix}$

② 计算协方差

$$C = \begin{bmatrix} \text{cov}(X_1, X_1) & \text{cov}(X_1, X_2) \\ \text{cov}(X_2, X_1) & \text{cov}(X_2, X_2) \end{bmatrix}$$

$$\text{cov}(X_1, X_1) = \frac{1}{5} [1.5 \times 1.5 + 0.5 \times 0.5 + 0.5 \times 0.5 + 0.5 \times 0.5 + 0.5 \times 0.5 + 1.5 \times 1.5] = 1.1$$

$$\text{cov}(X_1, X_2) = \frac{1}{5} [1.5 \times 0.5 - 0.5 \times 0.5 + 0.5 \times 1.5 + 0.5 \times 1.5 - 0.5 \times 0.5 + 0.5 \times 1.5] = 0.5$$

$$\text{cov}(X_2, X_2) = 1.1$$

$$\therefore C = \begin{bmatrix} 1.1 & 0.5 \\ 0.5 & 1.1 \end{bmatrix}$$

LDA:

① 计算每类均值 μ_0, μ_1

$$\mu_0 = [2, 3]^T$$

$$\mu_1 = [3, 2]^T$$

$$\text{全局均值 } \mu = [2.5, 2.5]^T$$

② 类内离散度 S_W

$$S_W = S_0 + S_1$$

$$\text{类别1 去中心化: } (-1, -1), (0, 0), (1, 1)$$

$$\text{类别2 去中心化: } (-1, -1), (0, 0), (1, 1)$$

$$\therefore S_0 = S_1 = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \begin{bmatrix} -1 & -1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 0 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$$

$$\therefore S_W = S_0 + S_1 = \begin{bmatrix} 4 & 4 \\ 4 & 4 \end{bmatrix}$$

③ 类间离散度 S_B

$$S_B = (\mu_0 - \mu)(\mu_0 - \mu)^T$$

$$\mu_0 - \mu = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$\therefore S_B = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \begin{bmatrix} -1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$$

④ 计算 S_W^{-1}

$$\text{因为 } S_W = \begin{bmatrix} 4 & 4 \\ 4 & 4 \end{bmatrix}, \text{行列式 } \begin{vmatrix} 4 & 4 \\ 4 & 4 \end{vmatrix} = 0$$

↓
奇异值。

添加微小扰动 $\epsilon = 0.001$

$$\therefore S_W^{\text{reg}} = \begin{pmatrix} 4.001 & 4 \\ 4 & 4.001 \end{pmatrix}$$

$$\begin{pmatrix} 4.001 & 4 \\ 4 & 4.001 \end{pmatrix}$$

$$\det(S_W^{\text{reg}}) = 0.008001$$

$$S_W^{\text{reg}-1} = \frac{1}{|S_W^{\text{reg}}|} \begin{bmatrix} 4.001 & -4 \\ -4 & 4.001 \end{bmatrix} = 125 \begin{bmatrix} 4.001 & -4 \\ -4 & 4.001 \end{bmatrix}$$

③ 求特征值及特征向量

$$\begin{bmatrix} 1.1-\lambda & 0.5 \\ 0.5 & 1.1-\lambda \end{bmatrix} = 0$$

$$(1.1-\lambda)^2 = 0.25$$

$$\therefore \lambda_1 = 0.6, \lambda_2 = 1.6$$

当 $\lambda_1 = 0.6$ 时

$$\begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = 0$$

$$0.5u_1 + 0.5u_2 = 0$$

$$u_1 = -u_2$$

$$\therefore \begin{bmatrix} 1 \\ -1 \end{bmatrix} \Rightarrow \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

当 $\lambda_2 = 1.6$ 时

$$\begin{bmatrix} -0.5 & 0.5 \\ 0.5 & -0.5 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = 0$$

$$\therefore -0.5u_1 + 0.5u_2 = 0$$

$$\therefore u_1 = u_2 = 1$$

$$\therefore \begin{bmatrix} 1 \\ 1 \end{bmatrix} \Rightarrow \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

$\therefore$ 降维时选择 $\lambda_2 = 1.6$

$$\therefore \begin{bmatrix} 1.5 & -0.5 \\ -0.5 & 0.5 \\ 0.5 & 1.5 \\ -0.5 & -1.5 \\ 0.5 & -0.5 \\ 1.5 & 0.5 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} -2 \\ 0 \\ 2 \\ -2 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} -\sqrt{2} \\ 0 \\ \sqrt{2} \\ -\sqrt{2} \\ 0 \\ \sqrt{2} \end{bmatrix}$$

$$\therefore S_w^{reg-1} = \begin{bmatrix} 500.125 & -500 \\ -500 & 500.125 \end{bmatrix}$$

$$M = S_w^{reg-1} \text{ (标准协)}$$

基于马氏距离的度量学习算法

基于马氏距离的度量学习算法

度量学习 (Metric Learning) 的目标是学习一个最优的距离度量, 使同类样本的距离尽可能小 (类内紧凑), 异类样本的距离尽可能大 (类间分离)。马氏距离 (Mahalanobis Distance) 作为度量学习的经典基础, 克服了欧氏距离未考虑特征相关性和量纲差异的缺陷, 其核心是通过学习一个正定矩阵 M (或线性变换矩阵 W , 满足 $M=W^TW$), 将原始特征空间映射到新空间, 最终距离定义为

$$d_M(x_i, x_j) = \sqrt{(x_i - x_j)^T M (x_i - x_j)}$$

M 为马氏矩阵 (正定对称矩阵), 当 $M=I$ (单位矩阵) 时, 退化为欧氏距离

算法流程 (线性马氏度量学习)

- 数据预处理: 对样本特征去均值 (每个特征减去全局均值);
- 计算散度矩阵: 分别计算类内散度矩阵 S_w 和类间散度矩阵 S_b ;
- 求解广义特征值问题: 计算 $S_w^{-1}S_b$ 的特征值和特征向量;
- 选择最优变换矩阵: 取前 k 个最大特征值对应的特征向量构成 W ;
- 计算马氏距离: 通过 $M = W^TW$ 得到马氏矩阵, 代入距离公式计算样本间距离。


例: 设数据集 $S=\{(1, 1), (2, 1), (1, 2), (2, 2), (4, 3), (5, 3), (4, 4), (5, 4)\}$, 令 $k=2$, 试用 $k-me$

x_1
 x_8

id	A_1	A_2	id	A_1	A_2
x_1	1	1	x_5	4	3
x_2	2	1	x_6	5	3
x_3	1	2	x_7	4	4
x_4	2	2	x_8	5	4

解: 数据集 S 可表示为一张二维表

而每个对象在平面上的相对位置可用下图所示:



① 距离聚类

$k=2$, 初始簇 $C_1=\{x_1\}$, $C_2=\{x_3\}$
质心为 $(1, 1)$, $(1, 2)$

$$\begin{aligned} d^2(x_1, x_2) &= 1 \\ d^2(x_3, x_2) &= 2 \quad \therefore x_2 \in C_1 \\ d^2(x_1, x_4) &= 2 \quad x_4 \in C_2 \\ d^2(x_3, x_4) &= 1 \\ d^2(x_1, x_5) &= 13 \quad x_5 \in C_2 \\ d^2(x_3, x_5) &= 10 \\ d^2(x_1, x_6) &= 20 \\ d^2(x_3, x_6) &= \end{aligned}$$

聚类过程				
计算步骤	最近簇高	最近的两个簇	合并后的新簇	簇个数 k
0	—	—	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	8
1	1	$\{x_1, x_2\}$	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	7
2	1	$\{x_3, x_4\}$	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	6
3	—	$\{x_1, x_2, x_3, x_4\}$	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	5
4	1	$\{x_5, x_6\}$	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	4
5	1	$\{x_7, x_8\}$	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	3
6	1	$\{x_5, x_6, x_7, x_8\}$	$\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$	2

初始 $\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}$

$$\begin{aligned} \therefore d^2(x_1, x_2) &= 1 \quad d^2(x_2, x_4) = 1 \quad d^2(x_1, x_3) = 1 \\ d^2(x_3, x_4) &= 2 \quad d^2(x_5, x_6) = d^2(x_5, x_7) = d^2(x_5, x_8) = 1 \\ d^2(x_6, x_7) &= d^2(x_6, x_8) = 1 \end{aligned}$$

选择 x_1, x_2 合并为 $\{x_1, x_2\}$
更新中心点为 ()

② 层次聚类 { 凝聚: AGNES
分裂: DIANA

AGNES算法

- 将每个对象当成一个初始簇 (最近)
- 计算每两个簇之间的距离, 选择距离最小的两个簇合并, 生成新的簇集
- 直到达到定义好的簇的数目

DIANA: 先令所有对象为一个簇, 计算每个对象 x_i 到其它对象 $x_j (i \neq j)$ 的平均相似度 (平均距离)
选择平均距离最大的分裂出去, 归到分裂簇

之后, 在原始簇中找一个点 q , 使得 q 到分裂簇的最短距离不大于 q 到原始簇中其余点距离的最小值, 将该点分裂至分裂簇

聚类: 将数据集中的样本划分为数个通常不相交的子集, 无监督学习

性能度量 (有效性指标) { 外部指标: Jaccard系数(JC)、FM指数(FMI)、Rand指数(RI)
内部指标: DB指数(DBI)、Dunn指数(DI)

基于距离的聚类分析

距离计算: ① 闵可夫斯基距离 $dist(x_i, x_j) = (\sum_{k=1}^n |x_{ik} - x_{jk}|^p)^{\frac{1}{p}}$, $p=1$: 曼哈顿距离, $p=2$: 欧氏距离。
② VDM (处理无序属性) $VDM_p(a, b) = \sum_{i=1}^n |\frac{m_{a,b_i}}{m_{a,a}} - \frac{m_{b,b_i}}{m_{b,b}}|^p$, 例如 {飞机, 火车, 高铁} 等无序属性。

k-means 聚类 “最小化平均误差准则”


- ① 从数据集S中随机选择K个对象作为K个簇的初始中心
- ② 对于数据集中的每个对象, 计算其与各簇中心的距离, 将其分配给与它最近的簇
- ③ 更新簇的中心, 即重新计算每个簇的均值
- ④ Until 所有簇中心不再发生变化

代码: `from sklearn.cluster import KMeans
X = np.array([[1,2],[1,4],[1,0],[4,2],[4,4],[4,0]])
kmeans = KMeans(n_clusters=2, random_state=0)
kmeans.fit(X)`

`labels = kmeans.predict(X)
plt.scatter(X[:,0], X[:,1], c=labels, s=50, cmap='viridis')
centers = kmeans.cluster_centers_
plt.scatter(centers[:,0], centers[:,1], c='red', s=200, alpha=0.5)
plt.title('k-Means Clustering')
plt.xlabel('Feature 1')
plt.ylabel('Feature 2')
plt.show()`

DBSCAN 算法: 基于密度的聚类算法

- ① 选取一个未标记类别的核心点, 并创建一个新簇
- ② 寻找所有从该核心点出发关于 ϵ 和 $MinPts$ 密度可达的点, 并标记为该簇
- ③ 重复这个过程, 直至处理完所有点, 即没有未标记簇的核心点




【例1】有如下表所示的数据集, 其在二维空间中的分布情况如图所示。用户输入 $\epsilon=1$, $MinPts=4$, 采用DBSCAN算法进行聚类的过程如下。

序号	属性1	属性2	序号	属性1	属性2
1	1	0	7	4	1
2	4	0	8	5	1
3	0	1	9	0	2
4	1	1	10	1	2
5	2	1	11	4	2
6	3	1	12	1	3

$\epsilon=1, Min=4$


层次聚类算法: 分簇聚的层次聚类和分裂的层次聚类

凝聚: 一种自底向上的策略, 首先将每个对象作为一个簇, 然后合并这些原子簇为越来越大的簇, 直到满足终止条件
分裂: 采用自顶向下的策略, 首先将所有对象置于一个簇中然后逐渐细分为越来越小的簇, 直到...




集成学习: 弱者联盟, 多个弱学习器的组合可以形成一个强学习器 → 能力变强且不易过拟合

- bagging: 模型独立, 互相平行, 代表算法: 随机森林
- boosting: 模型有序, 逐渐提升



Bagging

- ① 对原始数据集进行多次有放回的抽样生成多个不同的训练数据集
- ② 每一个训练数据集上训练一个基模型
- ③ 通过投票或平均等方法结合各个基模型的预测结果,



随机森林 (RF)

→ 有放回重复采样

- 步骤 ① 从样本集中用 **Bootstrap** 采样选出 n 个样本。
- ② 从所有属性中随机选择 K 个属性, 选择最佳分割属性作为节点建立 CART 决策树
- ③ 重复以上两个步骤 m 次, 即建立了 m 棵 CART 决策树
- ④ 这 m 棵 CART 决策树形成随机森林, 通过投票表决结果, 决定数据属于哪一类

代码: 分类 | 回归

分类

```
# 1. 导入必要的库  
from sklearn.ensemble import RandomForestClassifier  
from sklearn.model_selection import train_test_split  
from sklearn.metrics import accuracy_score  
from sklearn.datasets import make_classification  
# 2. 生成一个随机的二分类数据集 (你可以替换成自己的数据)  
X, y = make_classification(n_samples=1000, n_features=20, random_state=42)  
# 3. 将数据集分为训练集和测试集  
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)  
# 4. 创建随机森林分类器  
rf = RandomForestClassifier(n_estimators=100, random_state=42) # n_estimators  
# 5. 训练模型  
rf.fit(X_train, y_train)  
# 6. 在测试集上进行预测  
y_pred = rf.predict(X_test)  
# 7. 评估模型性能  
accuracy = accuracy_score(y_test, y_pred)  
print(f"模型准确率: {accuracy:.2f}")
```

回归

```
from sklearn.ensemble import RandomForestRegressor  
rfr = RandomForestRegressor(n_estimators=100, random_state=18)  
score = cross_val_score(rfr, X, y, cv=10, scoring='neg-mean-squared-error')
```

Bagging
Boosting
stacking

方法	优点	缺点	适用场景
Boosting	1. 精度高 2. 可以处理各种类型的预测任务	1. 容易过拟合 2. 对噪声敏感	数据质量较好，需要高精度
Bagging	1. 方差小 2. 不易过拟合	1. 计算量大 2. 存储开销大	数据噪声大，防止过拟合
Stacking	1. 灵活性强 2. 可以集成异质模型	1. 计算复杂度高 2. 调参困难	竞赛或关键应用场景

集成学习优势: ①提高准确性

②减少拟合

③增强模型的健壮性: 即使某个模型表现不佳, 其他模型予以补偿在准确预测

Bagging: 对原始数据集进行有放回的抽样, 生成多个不同的训练数据集, 每个训练数据集上训练个基模型, 最后通过投票或平均等方法结合各模型的预测结果

多数决定投票法
硬投票: 选择投票数最高的预测作为最终预测 (1, 1, 0 → 1)
软投票: 将每个模型中每个类的概率结合起来, 选择概率最高的
要使结果满足
基模型之间效果不能差别太大
基模型之间同质性较小

模型1
1: 80%
0: 20%

模型2
1: 60%
0: 40%

模型3
1: 20%
0: 80%

$\therefore 1 = \frac{80\% + 60\% + 20\%}{3} = 53\%$
 $0 = \frac{20\% + 40\% + 80\%}{3} = 47\%$ $\Rightarrow$ 选择1

x	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
y	1	1	1	-1	-1	-1	-1	-1	1	1

第一轮: $k=0.75, x \leq k, y = -1; x > k, y = 1$; 准确率 = 70%

x	0.1	0.4	0.5	0.6	0.7	0.8	0.8	0.9	0.9	1
y	1	-1	-1	-1	-1	-1	-1	-1	1	1

第二轮: $k=0.65, x \leq k, y = -1; x > k, y = 1$; 准确率 = 60%

x	0.1	0.2	0.3	0.4	0.5	0.8	0.9	1	1	1
y	1	1	1	-1	-1	-1	1	1	1	1

第三轮: $k=0.35, x \leq k, y = 1; x > k, y = -1$; 准确率 = 90%

x	0.1	0.2	0.3	0.4	0.4	0.5	0.7	0.7	0.8	0.9
y	1	1	1	-1	-1	-1	-1	-1	-1	-1

第四轮: $k=1, x \leq k, y = 1; x > k, y = -1$; 准确率 = 50%

x	0.1	0.1	0.2	0.5	0.6	0.7	0.7	0.8	0.9	0.9
y	1	1	1	-1	-1	-1	-1	-1	1	1

第五轮: $k=0.4, x \leq k, y = 1; x > k, y = -1$; 准确率 = 70%

x	0.1	0.1	0.2	0.5	0.6	0.6	0.6	1	1	1
y	1	1	1	-1	-1	-1	-1	-1	-1	-1

随机森林

随机森林的案例

描述: 根据已有训练集生成了对应的随机森林, 随机森林如何利用某一个人的5个字段来预测他的收入层次:

Age Gender Highest Educational Qualification Industry Residence

收入层次:
Band 1: Below \$40,000
Band 2: \$40,000 – \$50,000
Band 3: More than \$50,000

CART 1: Variable Age

Salary Band	1	2	3
Below 18	90%	10%	0%
19-27	85%	14%	1%
28-40	70%	23%	7%
40-55	60%	35%	5%
More than 55	20%	25%	55%

CART 2: Variable Gender

Salary Band	1	2	3
Male	70%	27%	3%
Female	75%	24%	1%

CART 3: Variable Education

Salary Band	1	2	3
High School	85%	10%	5%
Diploma	80%	14%	6%
Bachelors	77%	23%	0%
Master	62%	33%	5%

CART 4: Variable Residence

Salary Band	1	2	3
Metro	70%	20%	10%
Non-Metro	85%	20%	15%

CART 5: Variable Industry

Salary Band	1	2	3
Finance	65%	30%	5%
Manufacturing	60%	35%	5%
Others	75%	20%	5%

Boosting: 按顺序训练多个模型, 每个新模型在前个模型的残差上进行训练, 每个模型的权重会根据其性能进行调整, 以优化整体性能

多个弱学习器根据相应的权重构成一个强学习器

AdaBoost 权重
样本权重: 错误样本权重增大, 正确样本权重减小
弱学习器权重: 分类准确性越高, 权重越大

AdaBoost算法演示

- 以下表一维数据集为例, 分析AdaBoost算法是如何对该数据集进行分类的。

x	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
y	1	1	1	-1	-1	-1	-1	1	1	1

AdaBoost算法演示(续)

解答:

- Step1: 首先初始化10个样本的权值为:

$$W_1(i) = \frac{1}{10} = 0.1, (i = 1, 2, \dots, 10)$$

- Step2: 第1轮提升过程:

- 根据权重W1, 在数据集D上抽样产生训练集D1如下

提升第1轮	7	3	2	8	7	9	4	10	6	3
-------	---	---	---	---	---	---	---	----	---	---

- 在D1上训练产生一个基分类器h1, 该分类器的最佳分裂点为 $k=0.75, x \leq k, y = -1, x > k, y = 1$ 。使用该基分类器对原数据集D进行分类。
- 分类结果?

下面以原始数据集中的x=0.1为例加以说明最后的集成分类的过程:

x=0.1	分类结果	权重
第一轮h1	-1	1.738
第二轮h2	1	2.7844
第三轮h3	1	4.125365

$$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$$

$$= \text{sign}(-1 \times 1.738 + 1 \times 2.7844 + 1 \times 4.125365)$$

$$= \text{sign}(5.171) = 1$$

结果大于0

$$\text{sign}(x) = \begin{cases} 1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$

初始样本权重相等

$$W_1(i) = \frac{1}{10} (i = 1, 2, \dots, 10)$$

第一轮 $k=0.75, x \leq k, y = -1, x > k, y = 1$

预测结果

x	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
y	1	1	1	-1	-1	-1	-1	1	1	1

分类有错误的是 {1, 2, 3}

分类正确的是 {4, 5, 6, 7, 8, 9, 10}

① 计算误差 $e_1 = \frac{1}{N} \sum_{i=1}^N W_1(i) I(h_1(x_i) \neq y_i)$

$$= \frac{1}{10} [0.1 \times 1 + 0.1 \times 1 + 0.1 \times 1] = 0.03$$

② 计算h1学习器权重 $\alpha_1 = \frac{1}{2} \ln(\frac{1-e_1}{e_1}) = \frac{1}{2} \ln(\frac{1-0.03}{0.03}) = 1.738$

③ 更新样本权重 $W_{t+1}(i) = \frac{W_t(i)}{Z_t} \times \begin{cases} \exp(-\alpha_1) & \text{正确} \\ \exp(\alpha_1) & \text{错误} \end{cases}$

$$W_2(1) = W_2(2) = W_2(3) = \frac{W_1(1)}{Z_1} \times \exp(\alpha_1) = \frac{0.168}{Z_1}$$

$$W_2(4) = W_2(5) = W_2(6) = W_2(7) = W_2(8) = W_2(9) = W_2(10) = \frac{W_1(4)}{Z_1} \times \exp(-\alpha_1)$$

$$\sum W_2(i) = 1$$

$$\therefore \frac{0.168}{Z_1} \times 3 + \frac{0.0175}{Z_1} \times 7 = 1 \Rightarrow Z_1 = 1.8265$$

$$\therefore W_2(1) = W_2(2) = W_2(3) = \frac{0.168}{Z_1} = 0.311$$

第二轮 $k=0.05$

$$W_2(j) = \frac{0.0175}{Z_1} = 0.0095, j = 4, 5, \dots, 10.$$

x	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
y	1	1	1	-1	-1	-1	-1	1	1	1

$$e_2 = \frac{1}{10} [0.0095 \times 4] = 0.0038$$

$$\alpha_2 = \frac{1}{2} \ln(\frac{1-0.0038}{0.0038})$$

最终结果为 $\sum_{t=1}^T \alpha_t h_t(x)$

AdaBoost (自适应增强): 一种迭代算法, 针对同一训练集训练不同的分类器, 然后进行分类, 对于分类正确的样本权重低, 分类错误样本权重高

步骤:

- 基分类器 h_t 的误差 e_t 的计算:**

$$e_t = \frac{1}{N} \sum_{i=1}^N W_t(i) I(h_t(x_i) \neq y_i)$$

如果 $h_t(x_i) \neq y_i$ 为真, 则 $I(h_t(x_i) \neq y_i) = 1$, 否则为 0
- 基分类器权重的计算:**

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - e_t}{e_t} \right)$$
- 样本权重更新的计算:**

$$W_{t+1}(i) = \frac{W_t(i)}{Z_t} \times \begin{cases} \exp(-\alpha_t) & \text{if } h_t(x_i) = y_i \\ \exp(\alpha_t) & \text{if } h_t(x_i) \neq y_i \end{cases} = \frac{W_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

(其中, Z_t 是一个正规因子, 用来确保 $\sum_{i=1}^N W_{t+1}(i) = 1$.)
- 最终的强分类器:**

$$f(x) = \sum_{t=1}^T \alpha_t h_t(x)$$

```

from sklearn.ensemble import AdaBoostClassifier

from sklearn.tree import DecisionTreeClassifier

# 创建基模型
base_estimator = DecisionTreeClassifier()

# 创建AdaBoost分类器
ada_boost = AdaBoostClassifier(base_estimator=base_estimator, n_estimators=50)

# 训练模型
ada_boost.fit(X_train, y_train)

# 预测新数据
predictions = ada_boost.predict(X_test)
    
```

$$\frac{1}{\sqrt{2\pi} \cdot \sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$p[St+1|St] = p[St+1|S_1, \dots, S_t]$$

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

$$s.t. \quad y_i(w^T x_i + b) + \xi_i \geq 1, \quad \xi_i \geq 0$$

$$\min_{\lambda} \max_{\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^n \lambda_i (1 - y_i(w^T x_i + b) - \xi_i)$$

$$Corr(x, y) = \frac{Cov(x, y)}{\sqrt{Var(x)} \sqrt{Var(y)}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

$$\sum_{i=1}^n \lambda_i y_i x_i = w$$

$$\sum_{i=1}^n \lambda_i y_i = 0$$

$$\max_{\lambda} \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j x_i^T x_j$$

$$\min_{\lambda} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j x_i^T x_j$$

$$\begin{cases} C - \lambda - \mu = 0 \\ \lambda_i (1 - y_i(w^T x_i + b) - \xi_i) = 0 \\ \mu_i \geq 0, \lambda_i \geq 0 \end{cases}$$

代码:

"既能分的开, 也能分的好"

SVM (支持向量机): 关键目标是在特征空间中找到一个最优的超平面, 这个超平面向是 x_0 到超平面 $w^T x + b = 0$ 距离 不仅能够正确地分类数据, 还确保不同类别之间的间隔最大化

$$d = \frac{|w^T x_0 + b|}{\|w\|}$$

$$\max \frac{|w^T x + b|}{\|w\|}$$

有助于模型具有更好的泛化能力

目标函数:

$$\max \frac{1}{\|w\|} \Rightarrow \min \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w^T x_i + b) \geq 1 \quad s.t. \quad y_i(w^T x_i + b) \geq 1$$

① 构造拉格朗日函数

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i(w^T x_i + b) - 1)$$

② 对偶问题

$$\max_{\alpha} \min_{(w, b)} L(w, b, \alpha) \quad \sum_{i=1}^n \alpha_i x_i^T y_i$$

先求 $\min L(w, b, \alpha)$, 对 w, b 求偏导

$$\therefore \frac{\partial L}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^n \alpha_i y_i = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

③ 将结果代入拉格朗日函数中, 消去 w, b , 求解对偶问题

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$s.t. \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, \forall i$$

④ 用 SMO 求出 α

再通过 $w = \sum_{i=1}^n \alpha_i x_i y_i$ 求 w , $y_i(w^T x_i + b) = 1$ 解出 b

最大化间隔, 同时, 不满足约束条件, 尽可能少

软间隔: $\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$

$s.t. \quad g_i(w, b) = 1 - y_i(w^T x_i + b) - \xi_i \leq 0, \quad \xi_i \geq 0$

① 拉格朗日函数: $\min_{w, b, \xi} \max_{\lambda, \mu} L(w, b, \xi, \lambda, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \lambda_i [1 - \xi_i - y_i(w^T x_i + b)] - \sum_{i=1}^m \mu_i \xi_i$

$s.t. \quad \lambda_i \geq 0, \quad \mu_i \geq 0$

支持向量均值。


KKT 条件

$$\Rightarrow \begin{cases} \frac{\partial L}{\partial w_i} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i x_i = 0 \\ \lambda g_i(w) = 0 \Rightarrow \alpha_i [1 - y_i(w^T x_i + b)] = 0 \\ g_i(w) \leq 0 \Rightarrow 1 - y_i(w^T x_i + b) \leq 0 \\ \lambda_i \geq 0 \Rightarrow \alpha_i \geq 0 \end{cases}$$

硬间隔: 分类必须正确, 数据必须线性可分
(解决线性可分数据中噪声与轻微重叠问题)

软间隔: 允许分类错误, 引入松弛变量和正则化参数

核 SVM: 引入各种核函数
解决基本数据结构非线性问题



函数间隔: $y^{(i)}(w^T x^{(i)} + b) \Rightarrow |w^T x + b|$

几何间隔: $y^{(i)} \left(\frac{w^T}{\|w\|} \cdot x^{(i)} + \frac{b}{\|w\|} \right) \Rightarrow \frac{|w^T x + b|}{\|w\|}$

② 对偶问题 $\max_{\lambda, \mu} \min_{w, b, \xi} L(w, b, \xi, \lambda, \mu)$

$$\begin{cases} \frac{\partial L}{\partial w} = w - \sum_{i=1}^n \lambda_i y_i x_i = 0 \\ \frac{\partial L}{\partial b} = \sum_{i=1}^n \lambda_i y_i = 0 \\ \frac{\partial L}{\partial \xi_i} = C - \lambda_i - \mu_i = 0 \end{cases} \Rightarrow \begin{cases} \sum_{i=1}^n \lambda_i y_i x_i = w \\ \sum_{i=1}^n \lambda_i y_i = 0 \\ C = \lambda_i + \mu_i \end{cases}$$

$$\min_{\lambda} L(w, b, \xi, \lambda, \mu) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i y_i y_j x_i^T x_j$$

$$s.t. \sum_{i=1}^n \lambda_i y_i = 0, \lambda_i \geq 0, C - \lambda_i - \mu_i = 0$$

KKT 条件

$$\begin{cases} \alpha_i \geq 0, \mu_i \geq 0, \\ y_i(w^T x_i + b) - 1 + \xi_i \geq 0 \\ \alpha_i(y_i(w^T x_i + b) - 1 + \xi_i) = 0 \\ \xi_i \geq 0, \mu_i \xi_i = 0 \end{cases}$$

核函数：线性核函数，多项式核函数，高斯核函数

避免显式计算高维映射 直接在低维空间计算出等价的内积

线性核函数： $K(x_i, x_j) = x_i^T x_j$
 多项式核函数： $k(x_i, x_j) = (x_i^T x_j)^d$
 高斯核函数： $k(x_i, x_j) = \exp(-\frac{\|x_i - x_j\|^2}{2\sigma^2})$ → 需要调参
 拉普拉斯核函数： $k(x_i, x_j) = \exp(-\frac{\|x_i - x_j\|}{s})$

数学表达式	$K(x_i, x_j) = x_i \cdot x_j$	$K(x_i, x_j) = (\gamma x_i \cdot x_j + coef0)^d$	高斯核函数 (RBF)
核心参数	无额外参数	$\gamma, coef0, d$ (阶数)	γ (核宽度)
核心特点	线性映射, 无非线性能力	低维非线性映射	高维/无限维非线性映射
适用场景	数据线性可分、高维特征任务	数据有多项式规律的简单非线性任务	数据非线性可分、分布不明确的通用任务
优点	计算快、可解释性强	拟合适中, 低阶时速度较快	通用性强, 拟合复杂非线性关系
缺点	无法处理非线性数据	参数敏感, 高阶易过拟合	计算慢、 γ 调参难、无解释性

强化学习：通过从交互中学习来实现目标的计算方法

探索：选择未尝试过的或尝试次数少的，获取更多奖励信息
 利用：选择当前中奖概率最高的，最大化即时奖励

遗憾 $Regret(T) = T \cdot p^* - \sum_{t=1}^T r_t$
 ↓
 总步数

ϵ -贪心算法：以概率 ϵ 进行随机探索，以概率 $1-\epsilon$ 进行利用 (选择当前平均奖励最高的)

步骤：① 初始化 尝试次数=0, 平均奖励为0
 ② 随机生成 $rand \in [0, 1]$

③ 获得奖励 r , 更新尝试次数+1, 平均奖励 $\bar{r}_a = \bar{r}_a + \frac{1}{N_a}(r - \bar{r}_a)$

④ 输出各臂平均奖励、累积奖励和遗憾

步骤	随机数	决策 (探索/利用)	选择臂	奖励 (按真实概率)	各臂尝试次数 N	各臂平均奖励 $\bar{r}$	累积奖励	遗憾 (最优臂累积奖励 $= 0.7 \times t$)
1	0.05 (<0.1)	探索	随机选1	0 (p1=0.3, 模拟未中)	[1,0,0]	[0.0, 0.0, 0.0]	0	$0.7 \times 1 - 0 = 0.7$
2	0.8 (≥0.1)	利用	1 (当前唯一有数据的臂)	1 (p1=0.3, 模拟中奖)	[2,0,0]	[0.5, 0.0, 0.0]	1	$1.4 - 1 = 0.4$
3	0.08 (<0.1)	探索	随机选3	1 (p3=0.5, 模拟中奖)	[2,0,1]	[0.5, 0.0, 1.0]	2	$2.1 - 2 = 0.1$
4	0.92 (≥0.1)	利用	3 ($\bar{r}_3 = 1.0$ 最大)	0 (p3=0.5, 模拟未中)	[2,0,2]	[0.5, 0.0, 0.5]	2	$2.8 - 2 = 0.8$
5	0.15 (≥0.1)	利用	1或3 ($\bar{r}$ 均为0.5)	随机选1, 未中0 (p1=0.3)	[3,0,2]	[0.333, 0.0, 0.5]	2	$3.5 - 2 = 1.5$
6	0.03 (<0.1)	探索	随机选2	1 (p2=0.7, 模拟中奖)	[3,1,2]	[0.333, 1.0, 0.5]	3	$4.2 - 3 = 1.2$

中奖：奖励+1, 对应次数+1, $t+1$


未中奖：对应次数加1, $t+1$

马尔可夫性质：当且仅当某时刻的状态只取决于上一时刻的状态时，这个随机过程具有马尔可夫性质

$P[S_{t+1}|S_t] = P[S_{t+1}|S_1, \dots, S_t]$

马尔可夫过程

状态矩阵 $n \times n$, $p(s_j | s_i)$: 状态 s_i 转移到 s_j 的概率
 共有 n 种状态



马尔可夫过程的一个简单例子

$$P = \begin{matrix} & \begin{matrix} S_1 & S_2 & S_3 & S_4 & S_5 & S_6 \end{matrix} \\ \begin{matrix} S_1 \\ S_2 \\ S_3 \\ S_4 \\ S_5 \\ S_6 \end{matrix} & \begin{bmatrix} 0.9 & 0.1 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.6 & 0 & 0.4 \\ 0 & 0 & 0 & 0 & 0.3 & 0.7 \\ 0 & 0.2 & 0.3 & 0.5 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \end{matrix}$$

给定一个马尔可夫过程，就可以从某个状态出发，根据它的状态转移矩阵生成一个状态序列 (episode)，这个步骤也被叫做采样 (sampling)

从每个状态出发转移到其他状态的概率总和为 1

每行求和=1

马尔可夫奖励过程： $\langle S, P, r, \gamma \rangle$ $\gamma \in [0, 1]$
 有状态集合 $\uparrow$ 奖励函数 $\uparrow$ 折扣因子 $\uparrow$
 状态转移矩阵 $\downarrow$ 这具期望具有不确定性

回报：从 t 开始，所有奖励总和

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k}$$

选 S_1 为初始状态 $\gamma=0.5$, 采样到 1 条状态序列 $S_1 \rightarrow S_2 \rightarrow S_3 \rightarrow S_6$

$G_{S1} = R_{S1} + \gamma R_{S2} + \gamma^2 R_{S3} + \gamma^4 R_{S6}$


$$= -1 + 0.5 \times (-2) + (-2) \times (0.5) + 0.125 \times 0$$

$$= -1 - 1 - 0.5 = -2.5$$

价值V：从这个状态出发的未来累积奖励的期望

$V(s) = E[R_t + \gamma V(s_{t+1}) | s_t = s]$
→ 所有可能的下一状态

贝尔曼方程 $V(s) = r(s) + \gamma \sum_{s' \in S} p(s'|s) V(s')$



$$\begin{bmatrix} V(s_1) \\ V(s_2) \\ V(s_3) \\ V(s_4) \\ V(s_5) \\ V(s_6) \end{bmatrix} = \begin{bmatrix} -2.02 \\ -2.21 \\ 1.16 \\ 10.54 \\ 3.59 \\ 0 \end{bmatrix}$$

当前状态 S_4

S_{t+1} 可能为 S_5, S_6

$\therefore V(s_4) = 10 + 0.5 \times (0.3 \times 3.59 + 0.7 \times 0) \approx 10.54$

$V(s_4) = ?$ 验证

马尔可夫决策 MDP $\langle S, A, P, r, \gamma \rangle$
↑ 动作集合

加上动作
$$\begin{cases} Q^{\pi}(s,a) = r(s,a) + \gamma \sum_{s' \in S} P(s'|s,a) V^{\pi}(s') \\ V^{\pi}(s) = E_{\pi}[R_t + \gamma V^{\pi}(s_{t+1}) | s_t = s] \end{cases}$$

10.54

Q-learning：无模型的强化学习算法，无需知道环境转移模型，通过与环境交互的经验来更新Q值。
→ 表示在状态 S_t 执行动作 a 的长期累积奖励

目标：学习状态-动作价值函数 $Q(s,a)$

Q值更新公式：
$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)]$$

↑ 学习率 ↑ 执行动作 a_{t+1} 后获得即时奖励
↓ 时序差分误差

状态 \ 动作	0 (左)	1 (右)
0	0	0
1	0	0
2	0	0

1、环境规则

- 状态空间：仅3个状态 (0 = 起点、1 = 中间、2 = 目标)
- 动作空间：仅2个动作 (0 = 左移、1 = 右移)
- 奖励规则 (核心，决定交互反馈)：

当前状态	执行动作	新状态	即时奖励 (r)	说明
0	0 (左)	0	-2	撞墙，惩罚无效动作
0	1 (右)	1	-1	普通移动，鼓励尽快到目标
1	0 (左)	0	-1	普通移动
1	1 (右)	2	10	到达目标，正向奖励
2	0/1	2	0	已到目标，无奖励

$\alpha = 0.1$

$\gamma = 0.9$

$\epsilon = 0$

第一轮

① 当前状态 $S = 0$

② 动作选择： $a = 1$

③ 执行动作 $\begin{cases} \text{新状态 } S' = 1 \\ \text{即时奖励 } r = -1 \end{cases}$

④ 更新Q值

$$Q(0,1) = Q(0,1) + 0.1 \times [-1 + 0.9 \times \max(Q(1,0), Q(1,1)) - 0]$$

$$= 0 + 0.1 \times [-1 + 0.9 \times 0] = -0.1$$

$\therefore Q(0,1) = -0.1$

状态 \ 动作	0 (左)	1 (右)
0	0	-0.1
1	0	0
2	0	0

第二轮：① 当前状态 $S = 1$

② 选择动作 $a = 1$

③ 执行动作 $\begin{cases} \text{新状态 } S' = 2 \\ \text{即时奖励 } r = 10 \end{cases}$

④ 更新Q值

$$Q(1,1) = Q(1,1) + 0.1 \times [10 + 0.9 \times \max\{Q(2,1), Q(2,0)\} - Q(1,1)]$$

$$= 0 + 0.1 \times [10 + 0.9 \times 0 - 0] = 1$$

∴

状态 \ 动作	0 (左)	1 (右)
0	0	-0.1
1	0	1
2	0	0

第4轮：重置为起点，进入下一轮迭代

第三轮 ① 当前状态 $S = 2$

② 选择动作：比较 $Q(2,0), Q(2,1)$ 选择 0

③ 执行动作 $\begin{cases} \text{新状态 } S' = 2 \\ \text{即时奖励 } r = 0 \end{cases}$


④
$$Q(2,0) = Q(2,0) + 0.1 \times [-1 + 0.9 \times \max\{Q(2,0), Q(2,1)\} - Q(2,0)]$$

$$= 0 + 0.1 \times [0 + 0.9 \times 0 - 0] = 0$$

特征选择：从给定的特征集中选出任务相关特征子集(必须确保不会丢失重要特征)

↓
减轻维度灾难, 降低学习难度

相关特征
无关特征
冗余特征



两个关键环节: 子集搜索和子集评价

子集搜索 {
前向搜索: 逐渐增加相关特征
后向搜索: 从完整特征集开始, 逐渐减少特征
双向搜索: 每一轮逐渐增加相关特征, 减少无关特征

常见方法 {
过滤式
包裹式
嵌入式

1. 过滤法: ①特征进行预处理, 剔除与模型无关特征
(未考虑所使用的模型)
②计算每个变量与响应变量之间的相关性或互信息
③过滤掉某个阈值之下的特征

2. 打包法: 特征输入机器学习模型, 评估性能, 决定是否添加或删除特征以提高精度.
特点: 更精确, 但计算成本高. 不会意外删除本身不提供信息但和其他特征组合起来非常有用的特征.

3. 嵌入法: 将特征选择作为模型训练的一部分, 例: 决策树, L1正则化
特点: 实现计算成本与结果质量平衡.

精确度: 打包法 > 嵌入法 > 过滤法

计算成本: 打包法 > 嵌入法 > 过滤法

Step1: 数据预处理

①无量纲化: 标准化和区间缩放法

↓

$$x' = \frac{x - \bar{x}}{s}$$

↓ 标准差 = $\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$

$$x' = \frac{x - \min}{\max - \min}$$

区间缩放: `MinMaxScaler().fit_transform(x)`
二值化: `Binarizer(threshold=3).fit_transform(x)`
独热编码: `OneHotEncoder().fit_transform(y.reshape((-1,)))`
缺失值: `Imputer().fit_transform(data)`

方差选择法: 计算各个特征的方差, 根据阈值选择方差大于阈值的特征

相关系数法: 计算各个特征对目标值的相关系数以及相关系数的P值

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

$$\text{Cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

样本ID	特征1: 房屋面积 (m²)	特征2: 卧室数量 (个)	特征3: 距离市中心距离 (km)	目标变量: 房价 (万元)
1	80	2	5	120
2	100	3	3	180
3	120	3	2	220
4	90	2	4	150
5	110	3	1	200
6	70	2	6	100

$$\bar{x}_1 = \frac{370}{6} = 95$$
$$\bar{x}_2 = 2.5$$
$$\bar{x}_3 = 3.5$$
$$\bar{y} = 161.6$$

筛选目标: 设定相关系数绝对值阈值=0.7, 保留与房价相关系数绝对值≥0.7的特征, 并处理可能的多重共线性。

计算流程: 先计算各特征与目标的均值→再算协方差→接着算标准差→代入公式得相关系数→筛选并处理多重共线性。

↓ 计算变量与变量之间是否存在强相关, 是的话删除两者中与目标变量相关系数小的特征

互信息法:

$$I(X; Y) = \sum_{x \in X} \sum_{y \in Y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

→ 联系频率

① 连续型数值离散化

样本ID	特征1: 房屋面积 (m²) (连续, 线性正相关)	特征2: 装修等级 (离散: 1=简装, 2=中装, 3=精装)	特征3: 房龄 (年) (连续, 非线性负相关)	特征4: 所在楼层 (离散: 1=低, 2=中, 3=高)	目标: 房价 (万元)
1	80	1	10	2	120
2	100	3	5	3	180
3	120	3	3	3	220
4	90	2	8	2	150
5	110	3	2	3	200
6	70	1	15	1	100

筛选目标: 1. 计算各特征与房价的互信息值; 2. 设定阈值=0.3 (比特), 保留互信息≥0.3的特征; 3. 剔除特征间高冗余 (互信息≥0.5) 的特征。

连续值划分区间: 70-80, 80-90, 90-100, 100-110, 110-120

打包法: 递归特征消除


嵌入法: 基于递归顶的特征选择 (递归特征消除), 基于树模型

Bayes: $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ (贝叶斯公式)

全概率: $P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$

例2: 已知有一种疾病, 发病率是0.1%。针对这种疾病的测试非常准确:

如果有病, 则准确率是99% (即有1%未检出阳性);
如果没有病, 则误报率是2% (即有2%误报为阳性)。
现在, 如果一个人测试显示阳性, 请问他患病的概率是多少?



H: 发病

H-bar: 不发病

+: 检测为阳性

$P(H) = 0.001$

$P(\bar{H}) = 0.999$

$P(+|H) = 0.99$

$P(+|\bar{H}) = 0.02$

$P(H|+) = \frac{P(+|H) \cdot P(H)}{P(+)} \approx 4.72\%$

$P(+) = P(+|H)P(H) + P(+|\bar{H})P(\bar{H}) = 0.02$

(1) 两次检测均为阳性, 患病的概率

求 $P(H|++)$

$P(++|H) = 0.99 \times 0.99 = 0.9801$

$P(++|\bar{H}) = 0.02 \times 0.02 = 0.0004$

$\therefore P(++) = P(++|H)P(H) + P(++|\bar{H})P(\bar{H}) = 0.0013797$

$\therefore P(H|++) = \frac{P(++|H)P(H)}{P(++)} \approx 71.04\%$

(2) 三次均为阳性, 患病概率

$P(H|+++)=\frac{P(+++|H)P(H)}{P(+++)}$

$P(+++|H)=0.99 \times 0.99 \times 0.99 =$

$P(+++|\bar{H})=0.02 \times 0.02 \times 0.02 = 0.000008$

$P(+++)=P(+++|H)P(H)+P(+++|\bar{H})P(\bar{H})$

例: 在一个社会中, 男性和女性的比例基本是一样的, 也就是说如果把男性作为一类, 女性作为另一类, 那么两个类别的先验概率都是 0.5, 也可以说, 我们在路上随机遇到一个人, 他是男性和女性的概率各为 50%。如果我们在路上看到了一个人的背影, 发现他是长发, 那么他是男性或女性的概率会发生什么变化吗?

条件1: 男性留长发的概率是5%和女性留长发的概率是70%, 则 $P(\text{长发}|\text{男性})=0.05$, $P(\text{长发}|\text{女性})=0.7$. ——条件概率1

条件2: 设 $P(\text{男性})=50\%$, $P(\text{女性})=50\%$ ——先验概率2

$P(\text{男性}|\text{长发})=?$

$P(\text{男})=0.5 \quad P(\text{女})=0.5, P(\text{长发}|\text{男})=0.05, P(\text{长发}|\text{女})=0.7$

$P(\text{男}|\text{长发}) = \frac{P(\text{长发}|\text{男})P(\text{男})}{P(\text{长发})}$

$P(\text{长发}) = P(\text{长发}|\text{男}) \times P(\text{男}) + P(\text{长发}|\text{女}) \times P(\text{女})$

在N个样本为 y_m 时出现的次数
 y_m 训练样本数

$\rightarrow \prod_{i=1}^N P(a_i|y_m)$

朴素贝叶斯: 后验概率最大

第1步: 设 $X = \{a_1, a_2, a_3, \dots, a_n\}$ 为预测数据, 其中 a_i 是预测数据的特征值。

第2步: 设 $Y = \{y_1, y_2, y_3, \dots, y_m\}$ 为类别集合。

第3步: 计算 $P(y_1 | x), P(y_2 | x), P(y_3 | x), \dots, P(y_m | x)$ 。

第4步: 寻找 $P(y_1 | x), P(y_2 | x), P(y_3 | x), \dots, P(y_m | x)$ 中最大的概率 $P(y_k | x)$, 则 x 属于类别 y_k 。

$P(y_m|x) = \frac{P(x|y_m)P(y_m)}{P(x)}$

例: 词汇python: 蟒蛇 or “Python”

特征	分类
<i>Pythons</i> are constrictors that feed on birds and mammals	生物学
<i>Python</i> was originally developed as a scripting language	计算机科学
A 49-R-long <i>python</i> was found in China	生物学
<i>Python</i> has dynamic type system	计算机科学
<i>Python</i> with vivid scales	生物学
An Open source project developed by <i>python</i>	计算机科学
.....	

机器学习理论中, 这类词被称为“停用词”(stop word), 可事先将其去除, 不作为特征词参与样本训练, 从而减少学习时间。几乎每个搜索引擎都会维护一份“停用词表”(stop word list))。

$P(\text{生物学}|\vec{w}=\{\text{long, dynamic, source}\}) = \frac{P(\vec{w}=\{\text{long, dynamic, source}\}|\text{生物学})P(\text{生物学})}{P(\vec{w}=\{\text{long, dynamic, source}\})}$

$P(\vec{w}=\{\text{long, dynamic, source}\}|\text{生物学})$

$= P(\vec{w}=\{\text{long}|\text{生物学}\}) \times P(\vec{w}=\{\text{dynamic}|\text{生物学}\}) \times P(\vec{w}=\{\text{source}|\text{生物学}\})$

$= 0.1 \times 0.2 \times 0.1 = 0.002$

$P(\vec{w}=\{\text{long, dynamic, source}\}|\text{计算机科学})$

$= P(\vec{w}=\{\text{long}|\text{计算机}\}) \times P(\vec{w}=\{\text{dynamic}|\text{计算机}\}) \times P(\vec{w}=\{\text{source}|\text{计算机}\})$

$= 0.6 \times 0.1 \times 0.3 = 0.018$

$P(\text{生物学}) = P(\text{计算机科学}) = 0.5$

比较 $P(\vec{w}=\{\text{long, dynamic, source}\}|\text{生物学})P(\text{生物学})$ 和

$P(\vec{w}=\{\text{long, dynamic, source}\}|\text{计算机})P(\text{计算机})$

分类器

表 7-14 “特征-分类” 概率统计

词	计算机科学	生物学
<i>dynamic</i>	0.6	0.1
<i>constrictor</i>	0.0	0.6
<i>long</i>	0.1	0.2
<i>source</i>	0.3	0.1
<i>language</i>	0.7	0.1
<i>and</i>	0.95	0.95
.....		



训练
模式

假定有一篇新的句子或文档, 包含了 **long**、**dynamic**和 **source**三个单词, 那么这个句子或单词是在叙述生物学的**蟒蛇**还是计算机科学的**python**程序呢?

判定规则: 比较以下两个概率的大小:

- 出现 *long*、*dynamic*和 *source*条件下, *python*的类标号为**生物学**的概率, 记为 $P(\text{生物学}|\text{词}=\{\text{long, dynamic, source}\})$
- 出现 *long*、*dynamic*和 *source*条件下, *python*的类标号为**计算机科学**的概率, 记为 $P(\text{计算机科学}|\text{词}=\{\text{long, dynamic, source}\})$

类条件概率估计值 $p(x_i=v|y=c) = \frac{N_{x_i=v, y=c}}{N_{y=c}} = \frac{p(x_i=v, y=c)}{p(y=c)}$

分类属性和连续属性

【例】根据顾客消费数据，估算是否会购买计算机。预测一个未知样本 X 的类标号。

$X=\{ \text{年龄}=\text{"<=30"} , \text{年收入}=\text{medium}, \text{是否学生}=\text{yes}, \text{信用状况}=\text{fair} \}$

$P(C_{yes}|X)$ vs. $P(C_{no}|X)$

Rid	年龄	年收入	是否学生	信用状况	Class: 购买计算机
1	<=30	High	no	Fair	no
2	<=30	High	no	Excellent	no
3	31..40	High	no	Fair	yes
4	>40	Medium	no	Fair	yes
5	>40	Low	yes	Fair	yes
6	>40	Low	yes	Excellent	no
7	31..40	Low	yes	Excellent	yes
8	<=30	Medium	no	Fair	no
9	<=30	Low	yes	Fair	yes
10	>40	Medium	yes	Fair	yes
11	<=30	Medium	yes	Excellent	yes
12	31..40	Medium	no	Excellent	yes
13	31..40	High	yes	Fair	yes
14	>40	Medium	no	Excellent	no

31

$$p(C_{yes}) = \frac{9}{14} = 0.64 \quad p(C_{no}) = \frac{5}{14} = 0.357$$

$$p(C_{yes}|X) = \frac{p(X|C_{yes})p(yes)}{p(X)}$$

$$\text{求 } p(X|C_{yes}) = p(\text{年龄}=\text{"<=30"}|C_{yes}) \times p(\text{年收入}=\text{medium}|C_{yes}) \times p(\text{是否学生}=\text{yes}|C_{yes}) \times p(\text{信用状况}=\text{fair}|C_{yes})$$

$$= \frac{2}{9} \times \frac{4}{9} \times \frac{6}{9} \times \frac{6}{9} = 0.044$$

$$p(X|C_{no}) = \frac{3}{5} \times \frac{2}{5} \times \frac{1}{5} \times \frac{2}{5} = 0.019$$

$$\therefore p(X|C_{yes})p(yes) = 0.044 \times 0.64 \Rightarrow p(C_{yes}|X) > p(C_{no}|X)$$

$$p(X|C_{no})p(C_{no}) = 0.019 \times 0.357$$

会购买计算机

连续型特征

$$p(x_i=x|y=c) = \frac{1}{\sqrt{2\pi} \sigma_i} \exp\left(-\frac{(x-\mu_i)^2}{2\sigma_i^2}\right)$$

$$\mu = \frac{1}{L} \sum_{i=1}^L x_i, \quad \sigma^2 = \frac{1}{L} \sum_{i=1}^L (x_i - \mu)^2$$

【例】 $X=\{ \text{有房}=\text{否}, \text{婚姻状况}=\text{已婚}, \text{年收入}=\text{120K} \}$

年收入:

	均值 μ	标准差 σ	方差 σ^2
类no:	110	54.54	2975
类yes:	90	5	25

Tid	有房	婚姻状况	年收入	拖欠贷款
1	是	单身	125K	No
2	否	已婚	100K	No
3	否	单身	70K	No
4	是	已婚	120K	No
5	否	离婚	95K	Yes
6	否	已婚	60K	No
7	是	离婚	220K	No
8	否	单身	85K	Yes
9	否	已婚	75K	No
10	否	单身	90K	Yes

$$p(\text{年收入}=\text{120K}/\text{no}) = \frac{1}{\sqrt{2\pi} \cdot 54.54} e^{-\frac{(120-110)^2}{2 \times 2975}} = 0.0072$$

$$p(\text{年收入}=\text{120K}/\text{yes}) = \frac{1}{\sqrt{2\pi} \cdot 5.0} e^{-\frac{(120-90)^2}{2 \times 25}} = 1.22 \times 10^{-9}$$

【例】 $X=\{ \text{有房}=\text{否}, \text{婚姻状况}=\text{已婚}, \text{年收入}=\text{120K} \}$

$$P(\text{no}|X) = \frac{P(X|\text{no})P(\text{no})}{P(X)} = \frac{P(x_1|\text{no})P(x_2|\text{no})P(x_3|\text{no})P(\text{no})}{P(X)}$$

$$= \frac{4/7 \times 4/7 \times 0.0072 \times 7/10}{P(X)} = \frac{0.00168}{P(X)} \quad \text{拖欠还款=no}$$


$$P(\text{yes}|X) = \frac{P(X|\text{yes})P(\text{yes})}{P(X)} = \frac{P(x_1|\text{yes})P(x_2|\text{yes})P(x_3|\text{yes})P(\text{yes})}{P(X)}$$

$$= \frac{1 \times 0 \times 1.22 \times 10^{-9} \times 3/10}{P(X)} = \frac{0}{P(X)}$$

【例】该分类器的误差率等于普通鳄鱼的后验概率曲线下面的区域（从0到 $\hat{x}$ ）加上美洲鳄后验概率曲线下面的区域（从 $\hat{x}$ 到 ∞ ）：

$$Error = \int_0^{\hat{x}} P(\text{鳄鱼} | X) dX + \int_{\hat{x}}^{\infty} P(\text{美洲鳄} | X) dX$$

总误差称为贝叶斯误差率(Bayes error rate)。



误差率

【例】用概率分布模型估计类条件概率

【例】预测贷款拖欠。表中为银行预测贷款拖欠问题的训练集数据。现在要根据表中的数据，假设给定一个测试记录 X ，预测该贷款是否会拖欠还款。

Tid	有房	婚姻状况	年收入	拖欠贷款
1	是	单身	125K	No
2	否	已婚	100K	No
3	否	单身	70K	No
4	是	已婚	120K	No
5	否	离婚	95K	Yes
6	否	已婚	60K	No
7	是	离婚	220K	No
8	否	单身	85K	Yes
9	否	已婚	75K	No
10	否	单身	90K	Yes

$X=\{ \text{有房}=\text{否}, \text{婚姻状况}=\text{已婚}, \text{年收入}=\text{120K} \}$

平滑处理

1) 为什么需要平滑处理?

使用朴素贝叶斯，有时候会面临零概率问题。零概率问题，指的是在计算实例的概率时，如果某个量 x ，在观察样本库（训练集）中没有出现过，会导致整个实例的概率结果是0。在文本分类的问题中，当一个词语没有在训练样本中出现时，这个词基于公式统计计算得到的条件概率为0，使用连乘计算文本出现概率时也为0。这是不合理的，不能因为一个事件没有观察到就武断的认为该事件的概率是0

$$\text{拉普拉斯平滑处理 } p(x_i|y) = \frac{N_{y,v} + \alpha}{N_y + n\alpha}$$

$$\text{当 } \alpha=1 \text{ 时, } p(x_i=v|y=c) = \frac{N_{x_i=v, y=c} + 1}{N_{y=c} + n} \rightarrow \text{特征总数}$$

根据特征的分布类型，朴素贝叶斯可以采用不同的分布模型来描述特征的概率分布。

高斯分布朴素贝叶斯（Gaussian Naive Bayes）：当特征值是连续的并且近似正态分布时，可以使用高斯分布（正态分布）来建模。在这种情况下，我们假设每个特征的值都服从一个高斯分布，其参数（均值和方差）由训练数据估计。高斯朴素贝叶斯适用于特征值近似正态分布的情况，例如身高、体重等。

多项式分布朴素贝叶斯（Multinomial Naive Bayes）：当特征值是离散的并且每个特征可以取多个值时，可以使用多项式分布来建模。例如，文本分类中，每个单词的出现与否可以看作一个特征，每个特征可以取0或1的值（出现或不出现）。多项式分布朴素贝叶斯适用于文本数据或计数数据，其中特征的分布可以用多项式概率质量函数来描述。

伯努利分布朴素贝叶斯（Bernoulli Naive Bayes）：当特征值是二元的（即每个特征只能取0或1的值）时，可以使用伯努利分布来建模。伯努利朴素贝叶斯适用于二元特征，例如垃圾邮件分类中，每个特征可能表示某个特定单词是否出现在邮件中。伯努利分布是二项分布的特例，其中试验次数为1。

概率链式法则 $P(a, b) = P(a|b) P(b)$

$$P(a, b, c) = P(a|b, c) \times P(b, c) = P(a|b, c) P(b|c) P(c)$$

事件 $\left\{ \begin{array}{l} \textcircled{1} P(a|b) = P(a) \\ \textcircled{2} P(ab) = P(a)P(b) \\ \textcircled{3} P(a|b, c) = P(a|c) \end{array} \right.$ 独立

证明① $P(ab) = P(a|b)P(b)$

证明② $P(a|b, c) = P(a|c)$

证明③ $P(a, b, c) = \frac{P(a, b, c)}{P(b, c)} = \frac{P(a)P(b)P(c)}{P(b)P(c)} = P(a)$

贝叶斯网络：有向无环图，是一种模拟人类推理过程中因果关系的不确定性处理模型。节点表示随机变量。

$(E) \xrightarrow{P(H|E)} (H)$

$A \searrow B \swarrow C \rightarrow D$
 $\downarrow$
 E

求ABCDE同时发生概率 $P(A, B, C, D, E)$

$P(A, B, C, D, E) = P(A)P(C)P(B|AC)P(D|C)P(E|B)$

$P(x_1, x_2, x_3, x_4, x_5, x_6, x_7) = P(x_1)P(x_2)P(x_3)P(x_4|x_1, x_2, x_3)P(x_5|x_1, x_3)P(x_6|x_4)P(x_7|x_4, x_5)$

① head-to-head

$P(a, b, c) = P(a)P(b|a)P(c|a, b)$

② tail-to-tail

考虑c未知，跟c已知这两种情况：

在c未知的时候，有： $P(a, b, c) = P(c) * P(a|c) * P(b|c)$ ，此时，没法得出 $P(a, b) = P(a)P(b)$ ，即c未知时，a、b不独立。

在c已知的时候，有： $P(a, b|c) = P(a, b, c) / P(c)$ ，然后将 $P(a, b, c) = P(c) * P(a|c) * P(b|c)$ 带入式子中，得到： $P(a, b|c) = P(a, b, c) / P(c) = P(c) * P(a|c) * P(b|c) / P(c) = P(a|c) * P(b|c)$ ，即c已知时，a、b独立。

所以，在c给定的条件下，a、b被阻断(blocked)，是独立的，称之为tail-to-tail条件独立。

在c未知的条件下，a、b被阻断(blocked)，是独立的，称之为head-to-head条件独立

③ head-to-tail

$\left\{ \begin{array}{l} \text{c未知: } P(a, b, c) = P(a)P(c|a)P(b|c) \\ \text{无法推出 } P(a, b) = P(a)P(b), a, b \text{ 不独立} \\ \text{c已知: } P(a, b, c) = P(a, b|c)P(c) \\ \Rightarrow P(a, b|c) = \frac{P(a, b, c)}{P(c)} = \frac{P(a)P(c|a)P(b|c)}{P(c)} = P(a|c)P(b|c) \end{array} \right.$

吸烟 **P(S)**

肺癌 $P(C|S)$

支气管炎 $P(B|S)$

X-ray $P(X|C, S)$

Dyspnoea $P(D|C, B)$


CPD:

C	B	D=0	D=1
0	0	0.9	0.1
0	1	0.3	0.7
1	0	0.2	0.8
1	1	0.1	0.9

情况一：没有先验信息


- E: 锻炼; D: 饮食; HD: 心脏病;
- Hb: 心口痛; BP: 血压; CP: 胸痛

通过计算先验概率 $P(HD=Yes)$ 和 $P(HD=No)$ 来确定一个人是否可能患心脏病



$$P(HD=Yes, E=Yes, D=健康) = P(D=健康) \times P(E=Yes) \times P(HD=Yes | D=健康, E=Yes)$$

head-to-head $= 0.25 \times 0.7 \times 0.25$



∴ 心脏病独立, 锻炼, 饮食独立

$$\begin{aligned} P(HD=Yes) &= P(HD=Yes | D=健康, E=Yes) P(D=健康, E=Yes) + P(HD=Yes | D=健康, E=No) P(D=健康, E=No) \\ &\quad + P(HD=Yes | D=不健康, E=Yes) P(D=不健康, E=Yes) + P(HD=Yes | D=不健康, E=No) P(D=不健康, E=No) \\ &= 0.25 \times 0.7 \times 0.25 + 0.55 \times 0.25 \times 0.3 + 0.45 \times 0.75 \times 0.7 + 0.75 \times 0.3 \times 0.75 = 0.49 \\ P(HD=No) &= 1 - P(HD=Yes) = 0.51 \end{aligned}$$


情况二:

$$P(HD=Yes | BP=高) = \frac{P(BP=高 | HD=Yes) P(HD=Yes)}{P(BP=高)} = \frac{0.85 \times 0.49}{0.5185} = 0.8033$$

$$P(HD=No | BP=高) = \frac{P(BP=高 | HD=No) P(HD=No)}{P(BP=高)} = \frac{0.2 \times 0.51}{0.5185}$$

$$P(BP=高) = P(BP=高 | HD=Yes) P(HD=Yes) + P(BP=高 | HD=No) P(HD=No) = 0.5185$$

- E: 锻炼; D: 饮食; HD: 心脏病;
- Hb: 心口痛; BP: 血压; CP: 胸痛



情况三: 患心脏病后验概率

$$\begin{aligned} P(HD=Yes | BP=高, D=健康, E=Yes) \\ &= \frac{P(HD=Yes, BP=高, D=健康, E=Yes)}{P(BP=高, D=健康, E=Yes)} \end{aligned}$$

$$\begin{aligned} P(HD=Yes, BP=高, D=健康, E=Yes) &= P(E=Yes) P(D=健康) P(HD=Yes | E=Yes, D=健康) P(BP=高 | HD=Yes) \\ P(BP=高, D=健康, E=Yes) &= P(BP=高 | D=健康, E=Yes) P(D=健康, E=Yes) \\ P(HD=Yes | BP=高, D=健康, E=Yes) &= \frac{P(E=Yes) P(D=健康) P(HD=Yes | D=健康, E=Yes) P(BP=高 | HD=Yes)}{P(BP=高 | D=健康, E=Yes) P(D=健康, E=Yes)} \end{aligned}$$

$\therefore D, E$ 独立, $\therefore P(HD=Yes | BP=高, D=健康, E=Yes) = \frac{P(HD=Yes | D=健康, E=Yes) P(BP=高 | HD=Yes)}{P(BP=高 | D=健康, E=Yes)}$

类似于全概率公式: $P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$

即所有种可能相加

$\therefore BP=高 \begin{cases} HD=Yes - D=健康, E=Yes \\ HD=No - D=健康, E=Yes \end{cases}$

有2种可能


$\therefore P(BP=高 | D=健康, E=Yes) = P(BP=高 | HD=Yes) P(HD=Yes | D=健康, E=Yes) + P(BP=高 | HD=No) P(HD=No | D=健康, E=Yes)$

$\therefore$ 后验概率 $= \frac{0.85 \times 0.25}{0.85 \times 0.25 + 0.2 \times 0.75} = 0.5862$

实例2: 如果一篇文章是关于南海岛屿的新闻 (将这一事件记作 "News"), 文章可能包含介绍南海岛屿历史的内容 (这一事件记作 "History"), 但一般不会有太多介绍旅游风光的内容 (将事件 "有介绍旅游风光的内容" 记作 "Sightseeing")

如果有一篇文章中含有南海岛屿历史相关内容, 该文章是关于南海新闻的可能性多大?

News	Sightseeing	
	T	F
F	0.4	0.6
T	0.1	0.9



News	T	F
	0.2	0.8

Sightseeing	News	History	
		T	F
F	F	0.5	0.5
F	T	0.3	0.7
T	F	0.8	0.2
T	T	0.4	0.6

$P(N=T, S=F) = P(S=F | N=T) P(N=T) = 0.9 \times 0.2$

$P(S, N, H) = P(N, S) P(H | N, S)$

$P(N=T | H=T) = \frac{P(H=T | N=T) P(N=T)}{P(H=T)} = \frac{P(H=T, N=T)}{P(H=T)}$

$P(N=T) = 0.2$

$P(H=T) = P(H=T | S=F, N=T) P(S=F, N=T)$

$+ P(H=T | S=F, N=T) P(S=F, N=T)$

$+ P(H=T | S=T, N=T) P(S=T, N=T)$

$+ P(H=T | S=T, N=T) P(S=T, N=T)$

$0.3 \times 0.9 \times 0.2 + 0.4 \times 0.2 \times 0.1$

$0.3 \times 0.9 \times 0.2 + 0.4 \times 0.2 \times 0.1 + 0.8 \times 0.8 \times 0.4 + 0.5 \times 0.8 \times 0.6$

=

$P(H=T, N=T)$

$= \sum_{S \in \{T, F\}} P(H=T, S, N=T)$

$P(H=T) = \sum_{N \in \{T, F\}} \sum_{S \in \{T, F\}} P(H=T, S, N)$

$\therefore P(N=T | H=T) =$

6. 应用拉普拉斯平滑解决零概率问题：在文本分类中，某特征词在类

别 A 下出现 0 次，总特征次数为 10。使用拉普拉斯平滑 ($\alpha=1$) 计算该

特征的条件概率。

$$\frac{N_{x_i=v, y=c} + \alpha}{N_{y=c} + n\alpha}$$


$\alpha=1$, 特征: 出现, 不出现 $\therefore n=2$

$$\therefore p(x_i=v|y=c) = \frac{0+1}{10+2 \times 1} = \frac{1}{12}$$

7. 基于贝叶斯网络进行推理：网络包含节点 A、B、C，A 是 B 和 C

的父节点。已知 $P(A)=0.2$, $P(B|A)=0.9$, $P(B|\neg A)=0.1$, $P(C|A)=0.8$,

$P(C|\neg A)=0.2$ 。计算 $P(B)$ 和 $P(C|B)$ 。



$$p(A)=0.2 \text{ 已知}$$

$$\therefore p(B, C|A) = p(B|A) \cdot p(C|A)$$

$$p(A, B, C) = p(A) \times p(B|A) \times p(C|A) = 0.2 \times 0.9 \times 0.8 = 0.144$$

$$p(C|B) = \frac{p(B, C)}{p(B)}$$

$$p(B, C|A) = 0.9 \times 0.8 = 0.72$$

$$p(B, C|\neg A) = 0.1 \times 0.2 = 0.02$$

$$p(B) = p(B|A)p(A) + p(B|\neg A)p(\neg A) = 0.9 \times 0.2 + 0.1 \times 0.8 = 0.26$$

$$p(B, C) = p(B, C|A)p(A) + p(B, C|\neg A)p(\neg A) = 0.72 \times 0.2 + 0.02 \times 0.8$$


设计文本分类场景：使用朴素贝叶斯对邮件分类（作业答案或情书）。给

定训练数据中，作业消息占比 16/30，情书占比 13/30；关键词“红豆”

在作业中出现 1 次，在情书中出现 3 次；“喜欢”在作业中出现 3 次，在

情书中出现 2 次（总关键词出现次数：作业 15 次，情书 12 次）。若新邮

件含“红豆”和“喜欢”，计算其类别，给出主要算法和代码。



$$p(\text{情书}|\text{红豆}, \text{喜欢}) = \frac{p(\text{红豆}, \text{喜欢}|\text{情书})p(\text{情书})}{p(\text{红豆}, \text{喜欢})}$$

$$p(\text{作业}|\text{红豆}, \text{喜欢})$$

$$\frac{3}{14} \times \frac{4}{14} \times \frac{13}{30} \text{ VS } \frac{2}{17} \times \frac{4}{17} \times \frac{16}{30}$$

$$p(\text{红豆}|\text{情书}) = \frac{3+\alpha}{12+2\alpha} = \frac{4}{12+2} = \frac{4}{14}$$

$$p(\text{红豆}|\text{作业}) = \frac{1+\alpha}{15+2} = \frac{2}{17}$$


$$p(\text{喜欢}|\text{作业}) = \frac{3+\alpha}{15+2} = \frac{4}{17}$$

$$p(\text{作业}) = \frac{16}{30}$$

$$p(\text{情书}) = \frac{13}{30}$$

$$p(\text{喜欢}|\text{情书}) = \frac{2+\alpha}{12+2} = \frac{3}{14}$$

BP神经网络



Step 1 前向传播

1.输入层→隐含层：

计算神经元h1的输入加权和：

$$net_{h1} = w_1 * i_1 + w_2 * i_2 + b_1 * 1$$

$$net_{h1} = 0.15 * 0.05 + 0.2 * 0.1 + 0.35 * 1 = 0.3775$$

神经元h1的输出

$$out_{h1} = \frac{1}{1+e^{-net_{h1}}} = \frac{1}{1+e^{-0.3775}} = 0.593269992$$

同理，可计算出神经元h2的输出

$$out_{h2} = 0.596884378$$

$$\frac{1}{1+e^{-x}}$$

2.隐含层→输出层：

计算输出层神经元o1和o2的值

$$net_{o1} = w_5 * out_{h1} + w_6 * out_{h2} + b_2 * 1$$

$$net_{o1} = 0.4 * 0.593269992 + 0.45 * 0.596884378 + 0.6 * 1 = 1.105905967$$

$$out_{o1} = \frac{1}{1+e^{-net_{o1}}} = \frac{1}{1+e^{-1.105905967}} = 0.75136507$$

前向传播的过程结束，得到输出值为[0.75136079, 0.772928465]，与实际值[0.01, 0.99]相差还很远，现在我们对误差进行反向传播，更新权值，重新计算输出

9.任务：用 SVM 分类圆形边界数据

数据分布：正例位于 $x_1^2 + x_2^2 \leq 1$ ，负例位于 $x_1^2 + x_2^2 > 1$ 。

问题：

- (a) 应选择哪种核函数？解释原因。
- (b) 给出该核函数的数学表达式。

多项式
 $k(x^T z + c)^d$

$$C=0, d=2$$

$$\therefore k(x, z) = (x^T z)^2 = (x_1 z_1 + x_2 z_2)^2 \\ = x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2$$

$$\phi(x) = [x_1^2, \sqrt{2}x_1 x_2, x_2^2]^T$$

$$\phi(z) = [z_1^2, \sqrt{2}z_1 z_2, z_2^2]^T$$

8. 设核函数 $K(x, z) = (x^T z + 1)^2$ ，输入空间 $x = [x_1, x_2]^T$ 。求对应的特征映射函数 $\Phi(x)$ 。

$$x = [x_1, x_2]^T$$

$$\therefore z = [z_1, z_2]^T$$

$$\therefore x^T z = x_1 z_1 + x_2 z_2$$

$$\therefore k(x, z) = (x_1 z_1 + x_2 z_2 + 1)^2 \\ = x_1^2 z_1^2 + x_2^2 z_2^2 + 2x_1 z_1 x_2 z_2 + 2x_1 z_1 + 2x_2 z_2 + 1$$

$$\Phi(x) = [x_1^2, x_2^2, \sqrt{2}x_1 x_2, \sqrt{2}x_1, \sqrt{2}x_2, 1]^T$$

5. 给定线性可分数据集：

- 正例：(1,2), (2,3)
- 负例：(0,0), (1,0)

求最优分离超平面方程（需写出计算过程）。